

**PEMETAAN KERENTANAN BANJIR BERBASIS BIG DATA
MENGUNAKAN INTEGRASI DATA SPASIAL DAN
SOSIODEMOGRAFI**

IF25-40402 / MAHADATA



Kelompok 06

Bidang Topik : Kebencanaan - Banjir

Disusun Oleh :

Mekar Cendra Narwastu	(123140074)
Mei Disti Ayuningtias	(123140076)
Ribka Hana Josephine Situmorang	(123140103)
Diwan Ramadhani Dwi Putra	(123140116)
M. Hafizurrahman Akbar	(123140123)
M. Gymnastiar Syahputra	(123140135)
Bima Aryaseta	(123140177)

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2026**

ABSTRAK

Indonesia merupakan salah satu negara dengan risiko banjir yang tinggi, namun sistem analisis yang ada masih berfokus pada parameter fisik tanpa mempertimbangkan faktor kerentanan populasi secara komprehensif. Penelitian ini bertujuan untuk mengembangkan pendekatan pemetaan kerentanan banjir berbasis Mahadata dengan mengintegrasikan data spasial, seperti topografi dan curah hujan, serta data sosiodemografi seperti kepadatan penduduk dan kelompok rentan.

Metode yang digunakan melibatkan pengolahan dan integrasi data multi-sumber dari BMKG, BPS, dan instansi terkait, yang kemudian dianalisis menggunakan pendekatan spatio-temporal untuk menghasilkan skor kerentanan pada setiap wilayah. Proses analisis dilakukan melalui tahapan preprocessing, integrasi data, dan pembobotan indikator risiko untuk mengidentifikasi tingkat kerentanan secara sistematis.

Hasil penelitian ini diharapkan berupa peta kerentanan banjir yang mampu memberikan informasi yang lebih komprehensif dan mendukung pengambilan keputusan dalam mitigasi bencana, khususnya bagi instansi terkait seperti BNPB dan BPBD di wilayah Lampung. Penelitian ini juga diharapkan dapat memberikan kontribusi dalam pemanfaatan Mahadata untuk analisis risiko kebencanaan di Indonesia.

Kata Kunci: Analisis Spatio-Temporal, Banjir, Integrasi Data, Kerentanan, Mahadata, Mitigasi Bencana, Sosiodemografi.

DAFTAR ISI

ABSTRAK.....	2
DAFTAR ISI.....	3
DAFTAR TABEL.....	5
DAFTAR GAMBAR.....	6
BAB I	
PENDAHULUAN.....	7
1.1 Latar Belakang.....	7
1.2 Rumusan Masalah.....	8
1.3 Research Gap.....	9
1.4 Tujuan dan Kontribusi Penelitian.....	9
1.5 Struktur Paper.....	10
BAB II	
KAJIAN LITERATUR.....	11
2.1 Tinjauan Studi Terkait.....	11
2.1.1 Sistem Peringatan Dini dan Prediksi Bencana.....	11
2.1.2 Social Media Analytics untuk Deteksi Bencana Real-Time.....	11
2.1.3 Analisis Geospasial dan Pemetaan Spatio-Temporal.....	12
2.1.4 Integrasi Aspek Sosiodemografi dalam Penilaian Risiko.....	12
2.2 Tabel Perbandingan Studi Terdahulu.....	12
2.3 Research Gap dan Posisi Penelitian.....	16
BAB III	
METODOLOGI.....	18
3.1 Arsitektur Sistem.....	18
3.2 Sumber Data dan Pengumpulan Data.....	19
3.3 Pipeline data dan Preprocessing.....	21
3.4 Metode Analisis/Model.....	22
BAB IV	
DESAIN EKSPERIMEN.....	24
4.1 Skenario Eksperimen.....	24
4.2 Baseline/Pembandingan.....	24
4.3 Environment Eksperimen.....	25
4.4 Metriks Evaluasi.....	25
BAB V	
HASIL YANG DIHARAPKAN.....	26
5.1 Hipotesis Hasil.....	26
5.2 Perancangan Visualisasi Hasil.....	26
5.3 Kontribusi yang Diharapkan.....	27

6.1 Kesimpulan.....	28
6.2 Keterbatasan Penelitian.....	28
6.3 Rencana Pengembangan.....	29
REFERENSI.....	30
LAMPIRAN.....	32

DAFTAR TABEL

Tabel 2.1 Perbandingan Studi Terdahulu Penerapan Big Data di Bidang Kebencanaan.....	13
Tabel 3.1. Sumber dan Pengumpulan Data Penerapan Big Data di Bidang Kebencanaan.....	20
Tabel 3.2 Hasil Skor Kerentanan.....	23
Tabel 4.1 Komponen yang dibutuhkan saat Eksperimen.....	25

DAFTAR GAMBAR

Gambar 3.1 Arsitektur Lambda.....	19
Gambar 5.1 Contoh Choropleth Map.....	26

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia secara geografis berada di kawasan dengan tingkat kejadian bencana hidrometeorologi yang sangat tinggi, di mana banjir secara konsisten menjadi jenis bencana yang paling dominan. Data historis menunjukkan ribuan kejadian setiap tahunnya yang menimbulkan kerugian ekonomi dan sosial yang besar. Provinsi Lampung, sebagai gerbang Pulau Sumatera dengan laju urbanisasi yang pesat, menghadapi kondisi serupa, di mana perkembangan wilayah seringkali tidak diimbangi dengan kesiapan infrastruktur mitigasi. Namun demikian, efektivitas Sistem Peringatan Dini (*Early Warning System*) yang ada saat ini masih terbatas pada model konseptual dasar tanpa adanya integrasi yang kuat antara pemantauan kondisi fisik dan kesiapan masyarakat di lapangan [13].

Dalam era transformasi digital, volume data kebencanaan telah berkembang hingga mencapai skala yang sulit dikelola dengan pendekatan komputasi konvensional. Data penginderaan jauh dan pemetaan multisumber menghasilkan data dalam jumlah besar yang terus meningkat secara eksponensial, sehingga membutuhkan algoritma tingkat tinggi untuk analisis spasial dan *time-series* yang efisien [14]. Kondisi ini menuntut penerapan analitik Mahadata dalam konteks operasi kemanusiaan dan penanggulangan bencana untuk mengatasi lonjakan data di masa mendatang [11]. Di Lampung, ketersediaan data curah hujan dari BMKG, citra satelit multitemporal, serta data sosiodemografi dari BPS menimbulkan tantangan pada aspek *Variety* (keberagaman) dan *Velocity* (kecepatan), sehingga integrasi data dari berbagai sumber menjadi kebutuhan utama untuk memperoleh gambaran situasi yang menyeluruh.

Permasalahan utama dalam pemetaan risiko saat ini terletak pada ketergantungan terhadap pendekatan *single-source* yang hanya berfokus pada parameter fisik. Sebagian besar sistem manajemen bencana masih menghadapi keterbatasan dalam hal skalabilitas serta kemampuan untuk melakukan fusi data heterogen secara efektif [12]. Penelitian terkini di wilayah pulau utama Indonesia menunjukkan bahwa analisis penggunaan lahan perlu dikombinasikan dengan analisis sosial ekonomi untuk menghasilkan strategi mitigasi banjir yang lebih tepat sasaran [2]. Tanpa mempertimbangkan dimensi manusia, seperti kepadatan penduduk dan karakteristik kelompok rentan, peta kerentanan yang dihasilkan akan kurang relevan secara sosial dan tidak optimal dalam mendukung ketahanan masyarakat terhadap risiko bencana [9].

Tantangan teknis dalam pengolahan data yang tersebar di wilayah luas seperti Lampung dapat diatasi melalui perkembangan teknologi komputasi terdistribusi. Pemanfaatan platform

berbasis *cloud* seperti Google Earth Engine (GEE) memungkinkan analisis multitemporal terhadap dinamika banjir serta perubahan tutupan lahan dengan tingkat akurasi yang tinggi dan efisiensi waktu yang lebih baik [4]. Selain itu, arsitektur pemrosesan di tingkat *edge* dan fusi multimodal diperlukan untuk mempercepat proses penggabungan berbagai aliran data heterogen, seperti data sensor IoT dan data media sosial, guna mendukung respons yang mendekati *real-time* saat bencana terjadi [6], [8]. Pendekatan ini memungkinkan pemetaan kerentanan secara multidimensi yang mencakup aspek fisik, sosial, dan infrastruktur secara terpadu [3].

Melalui integrasi data spasial (topografi, elevasi, tutupan lahan) dengan data sosiodemografi (kependudukan dan kelompok rentan), penelitian ini berupaya mengisi kesenjangan dalam literatur terkait model kerentanan banjir yang dinamis di Indonesia. Dengan memanfaatkan arsitektur Mahadata yang bersifat skalabel, sistem yang dikembangkan diharapkan mampu memberikan estimasi risiko yang lebih akurat bagi instansi seperti BNPB dan BPBD di Provinsi Lampung. Penekanan pada fusi data heterogen ini tidak hanya ditujukan untuk mengidentifikasi ancaman banjir, tetapi juga untuk memastikan bahwa alokasi sumber daya mitigasi dilakukan secara lebih efektif berdasarkan tingkat kerentanan aktual masyarakat terdampak.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang diidentifikasi dalam penelitian ini adalah sebagai berikut.

1. Bagaimana merancang arsitektur big data yang mampu mengintegrasikan data spasial (topografi, curah hujan, tutupan lahan) dan data sosiodemografi (kepadatan penduduk, kelompok rentan) untuk pemetaan kerentanan banjir di Lampung?
2. Bagaimana membangun pipeline pemrosesan data big data yang mampu menangani volume dan variety data besar untuk menghasilkan skor kerentanan secara sistematis?
3. Bagaimana mengevaluasi performa pemetaan kerentanan menggunakan metrik akurasi dan validasi data historis banjir di wilayah Lampung?

1.3 Research Gap

Kajian terhadap literatur terdahulu mengidentifikasi beberapa celah penelitian yang menjadi motivasi utama penelitian ini. Pertama, mayoritas penelitian yang menggunakan pendekatan single-source, yakni hanya memanfaatkan satu jenis sumber data misalnya hanya data spasial (topografi atau curah hujan) atau hanya citra satelit tanpa mengintegrasikannya dengan data sosiodemografi secara simultan. Padahal, ketepatan pemetaan kerentanan banjir sangat bergantung pada kelengkapan dan korelasi antar sumber data spasial dan sosiodemografi.

Kedua, uji skalabilitas sistem masih sangat terbatas dalam literatur yang ada. Sebagian besar penelitian dilakukan dalam lingkungan lab terkontrol dengan dataset yang relatif kecil, sehingga kemampuan sistem untuk beroperasi pada skala data nyata di wilayah provinsi seperti Lampung masih belum terbukti.

Ketiga, konteks Indonesia hampir tidak mendapat perhatian dalam penelitian internasional. Tantangan spesifik Indonesia seperti keterbatasan konektivitas di daerah terpencil, regulasi data BNPB dan BMKG, serta karakteristik bencana tropis berbeda secara signifikan dari konteks negara-negara yang banyak diteliti.

1.4 Tujuan dan Kontribusi Penelitian

Berdasarkan rumusan masalah dan research gap yang telah diidentifikasi, penelitian ini memiliki tujuan sebagai berikut:

1. Merancang arsitektur big data untuk integrasi data spasial dan sosiodemografi dalam pemetaan kerentanan banjir.
2. Mengimplementasikan pipeline pemrosesan data big data untuk menghasilkan skor dan peta kerentanan.
3. Mengevaluasi performa pemetaan menggunakan metrik akurasi, kappa, dan validasi historis.

Adapun kontribusi penelitian ini terhadap ilmiah adalah sebagai berikut:

1. Kerangka big data untuk pemetaan kerentanan banjir di Lampung yang mengintegrasikan data spasial dan sosiodemografi secara komprehensif.
2. Pipeline pemrosesan data yang skalabel untuk analisis multi-sumber di Indonesia.
3. Peta kerentanan banjir berbasis Mahadata sebagai referensi bagi BNPB/BPBD Lampung dan penelitian lanjutan.

1.5 Struktur Paper

Paper ini disusun dalam tujuh bagian yaitu:

- Bagian I ini menyajikan pendahuluan yang mencakup latar belakang, rumusan masalah, research gap, tujuan, dan kontribusi penelitian.
- Bagian II memaparkan kajian literatur terkait penerapan big data di bidang kebencanaan beserta sintesis research gap.
- Bagian III menjelaskan metodologi yang diusulkan, meliputi arsitektur sistem, pipeline data, dan metode analisis yang digunakan.
- Bagian IV mendeskripsikan desain eksperimen beserta baseline perbandingan.
- Bagian V menguraikan hasil yang diharapkan dari penelitian ini.
- Bagian VI menyimpulkan penelitian dan mengidentifikasi keterbatasan serta arah pengembangan di masa depan.
- Bagian VII menyajikan daftar pustaka.

BAB II

KAJIAN LITERATUR

2.1 Tinjauan Studi Terkait

Penelitian mengenai pemanfaatan Mahadata dalam manajemen bencana telah mengalami pergeseran dari sekadar pemantauan kondisi fisik menuju analisis risiko yang lebih menyeluruh. Tantangan utama dalam pemetaan kerentanan saat ini terletak pada bagaimana mengintegrasikan kompleksitas faktor lingkungan fisik dengan dinamika sosial masyarakat. Oleh karena itu, kajian literatur ini difokuskan pada perkembangan sistem peringatan dini, pemanfaatan media sosial, pengolahan data spasial berskala besar, serta integrasi aspek sosiodemografi dalam evaluasi risiko.

2.1.1 Sistem Peringatan Dini dan Prediksi Bencana

Efektivitas sistem peringatan dini (EWS) sangat dipengaruhi oleh kemampuan arsitektur sistem dalam mengolah data secara adaptif. Chovanec dkk. [13] menyatakan bahwa EWS modern perlu dirancang berbasis komponen agar integrasi data dan penyebaran informasi dapat berlangsung secara selaras. Dalam hal pengumpulan data lapangan, pengembangan platform pemantauan hidrologi nirkabel berbiaya rendah telah terbukti mampu menyediakan resolusi spasial dan temporal yang lebih tinggi dibandingkan metode konvensional [10].

Secara teknis, perkembangan prediksi banjir saat ini banyak didominasi oleh pendekatan berbasis data (*data-driven*) dengan penggunaan algoritma Deep Learning seperti LSTM untuk menangkap pola curah hujan dan limpasan [7]. Meskipun tingkat akurasi terus meningkat, kajian terhadap teknologi AI menunjukkan bahwa integrasi data dari berbagai sumber (multi sumber) masih menjadi tantangan utama dalam mengekstraksi pola bencana secara optimal [14]. Selain itu, pemanfaatan Mahadata terbukti penting untuk mengurangi latensi dalam pemrosesan data pada sistem peringatan dini, terutama di wilayah yang rawan siklon dan cuaca ekstrem [5].

2.1.2 Social Media Analytics untuk Deteksi Bencana Real-Time

Media sosial kini berperan sebagai sensor sosial yang bernilai dalam meningkatkan kesadaran situasi secara real-time. Gao dkk. [6] menunjukkan bahwa pemanfaatan data multimodal, berupa teks dan gambar dari media sosial, dengan model ekstraksi informasi seperti ERNIE dan Deeplab v3+, mampu memberikan gambaran kondisi lapangan yang lebih terkini. Integrasi teknologi edge juga diusulkan untuk mempercepat pemrosesan data tersebut dengan latensi yang lebih rendah guna mendukung respons manajemen krisis yang lebih cepat

[8]. Namun demikian, penggunaan data media sosial tetap memerlukan validasi silang dengan data sensor fisik untuk mengatasi permasalahan noise dan sifat data yang tidak terstruktur.

2.1.3 Analisis Geospasial dan Pemetaan Spatio-Temporal

Pengolahan data spasial berskala besar saat ini banyak memanfaatkan platform berbasis cloud guna meningkatkan efisiensi. Aldiansyah dkk. [4] menunjukkan bahwa penggunaan Google Earth Engine (GEE) dalam analisis multitemporal terhadap data satelit multi sensor dapat mempercepat identifikasi dinamika banjir serta perubahan tutupan lahan secara signifikan. Untuk mendukung kecepatan respons, dikembangkan arsitektur *distributed fusion* yang mampu memproses aliran data heterogen dari penginderaan jauh secara paralel [6]. Pendekatan geospasial ini tidak hanya digunakan untuk memetakan genangan, tetapi juga mulai mengintegrasikan dimensi kerentanan yang lebih luas, termasuk aspek infrastruktur dan lingkungan di wilayah pesisir [3].

2.1.4 Integrasi Aspek Sosisodemografi dalam Penilaian Risiko

Salah satu kekurangan utama dalam literatur saat ini adalah minimnya perhatian terhadap faktor manusia dalam model prediksi berbasis fisik. Srivastava dkk. [9] menunjukkan bahwa penambahan variabel sosio-ekonomi dalam model Machine Learning dapat meningkatkan akurasi prediksi dampak bencana secara signifikan. Di Indonesia, penelitian oleh Sigit dkk. menegaskan bahwa pemetaan risiko banjir yang efektif harus menggabungkan karakteristik sosial masyarakat [1] serta analisis tutupan lahan dengan data statistik sosisodemografi dari BPS untuk merumuskan strategi mitigasi yang lebih tepat sasaran [2].

Pemanfaatan analitik Mahadata pada akhirnya ditujukan untuk menghasilkan nilai tambah (*value*) dalam operasi kemanusiaan, di mana pengambilan keputusan tidak hanya didasarkan pada besarnya kejadian banjir, tetapi juga pada tingkat kerentanan populasi yang terdampak [11]. Dengan mengintegrasikan seluruh komponen tersebut, sistem manajemen bencana dapat berkembang dari sekadar alat pemantauan menjadi platform pengambilan keputusan strategis yang lebih scalable [12].

2.2 Tabel Perbandingan Studi Terdahulu

Tabel 2.1 berikut menyajikan perbandingan komprehensif dari sepuluh studi terdahulu yang paling relevan dengan penelitian ini, ditinjau dari aspek metode/teknologi, dataset, hasil utama, serta kelebihan dan kekurangan masing-masing.

Tabel 2.1 Perbandingan Studi Terdahulu Penerapan Big Data di Bidang Kebencanaan

No	Judul Paper (Tahun)	Metode / Teknologi	Dataset	Hasil Utama	Kelebihan & Kekurangan
1	<i>Novel data-driven model for flood prediction using big data: Social resilience and risk management (2025)</i>	Hybrid Machine Learning (Pendekatan Data-Driven)	Data Hidrologi-Meteorologi & Data Sosial-Demografi (kerentanan masyarakat).	Membuktikan bahwa elemen sosio-ekonomi secara signifikan meningkatkan akurasi analisis dampak dan prediksi banjir.	Mempertimbangkan aspek ketahanan sosial (social resilience) yang sering diabaikan dalam model fisik. Namun integrasi dengan data spasial resolusi tinggi (remote sensing) masih belum dieksplorasi secara mendalam.
2	<i>Big data and artificial intelligence-driven natural disaster prediction and prevention: Technological advances and prospects (2024)</i>	Deep Learning & Machine Learning	Multisource Data (Sejarah bencana, data topografi/spasial skala besar).	AI sangat efektif untuk mengekstraksi pola dari berbagai sumber data dan memetakan zona rawan bencana secara akurat.	Memberikan tinjauan komprehensif tentang bagaimana AI menangani data dari berbagai dimensi (spasial, temporal). Namun, sangat bergantung pada standarisasi format data; menuntut pra-pemrosesan data yang sangat kompleks.
3	<i>Flood Risk Assessment Focusing on Exposed Social Characteristics in Central Java, Indonesia (2023)</i>	Analisis Geospasial & Matriks Risiko	Topografi, data sosial-ekonomi, dan profil kependudukan (studi kasus Jawa Tengah).	Eksposur karakteristik sosial terbukti memperkuat presisi pemetaan risiko banjir dibandingkan hanya menggunakan variabel curah hujan/alam.	Sangat aplikatif dan relevan dengan konteks kependudukan di Indonesia. Meskipun demikian, penelitian ini belum menerapkan arsitektur komputasi terdistribusi untuk pengolahan data secara real-time.
4	<i>Land Cover and Socioeconomic Analysis for Recommended Flood Risk Reduction Strategies in Java Island, Indonesia (2024)</i>	Overlay Spasial & Analisis Tutupan Lahan	Data inaRISK, citra satelit tutupan lahan, data statistik sosiodemografi BPS (Pulau Jawa).	Strategi mitigasi banjir wajib diselaraskan dengan tutupan lahan dan tingkat kerentanan ekonomi masyarakat setempat.	Berhasil memadukan data lingkungan fisik dan data ekonomi dalam skala besar. Sayangnya, analisis yang dilakukan masih bersifat statis dan tidak memperhitungkan kecepatan aliran data (velocity) dalam situasi darurat.

No	Judul Paper (Tahun)	Metode / Teknologi	Dataset	Hasil Utama	Kelebihan & Kekurangan
5	<i>Geospatial Approach to Assess Flash Flood Vulnerability in a Coastal District of Bangladesh: Integrating the Multifaceted Dimension of Vulnerabilities (2025)</i>	Multi-Criteria Decision Analysis (MCDA) Berbasis GIS	Citra satelit, model elevasi digital (DEM), dan indeks kerentanan masyarakat pesisir Bangladesh.	Fusi data dari dimensi fisik dan demografi menghasilkan zonasi kerentanan banjir bandang yang presisi.	Metodologi integrasi kerentanan multidimensi diuraikan dengan sangat detail. Akan tetapi, studi ini dilakukan di luar konteks Indonesia dan belum memanfaatkan kerangka kerja Mahadata (seperti Apache Spark) untuk tahap pengolahannya.
6	<i>Multi-Temporal Analysis of Flood Dynamics and Land Use Land Cover Change in the Konawehea Watershed Using Multi-Sensor Remote Sensing Approach (2026)</i>	Cloud Computing (Google Earth Engine) & Multi-Sensor Remote Sensing	Big Data spasial (citra satelit multitemporal dan multi-sensor).	Eksekusi melalui platform GEE mempercepat analisis perubahan tutupan lahan dan dinamika luasan banjir secara drastis.	Membuktikan efisiensi dalam penyelesaian masalah Volume pada pengolahan citra spasial berukuran masif. Namun, fokus utamanya hanya pada topografi fisik tanpa memperhitungkan beban sosiodemografi masyarakat yang terdampak.
7	<i>Review of big-data and AI application in typhoon-related disaster risk early warning in Typhoon Committee region (2023)</i>	Systematic Review (AI & Big Data)	Berbagai literatur hidrometeorologi dan manajemen bencana.	Adopsi Mahadata krusial untuk mengatasi masalah latensi dalam pemrosesan sistem peringatan dini bencana cuaca.	Memberikan sintesis komprehensif mengenai tren komputasi sistem peringatan dini modern. Sayangnya, tinjauan ini terlalu berfokus pada bencana angin topan sehingga kurang relevan secara langsung untuk dinamika banjir luapan.
8	<i>Enhancing Disaster Situation Awareness Through Multimodal Social Media Data: Evidence from Typhoon</i>	Multimodal Deep Learning & Social Media Analytics	Big Data tidak terstruktur (teks dan gambar dari jejaring sosial).	Ekstraksi informasi multimodal meningkatkan kemampuan identifikasi situasi darurat secara aktual dan real-time.	Mampu menangani keberagaman data (Variety) yang tidak terstruktur dengan kecepatan tinggi. Namun, penelitian ini tidak mengintegrasikan data lingkungan spasial dari sensor instansi resmi (seperti BMKG atau BNPB).

No	Judul Paper (Tahun)	Metode / Teknologi	Dataset	Hasil Utama	Kelebihan & Kekurangan
	<i>Haikui (2025)</i>				
9	<i>Evolution of Data-Driven Flood Forecasting: Trends, Technologies, and Gaps—A Systematic Mapping Study (2025)</i>	Systematic Mapping Study	Kepustakaan global terkait peramalan banjir data-driven.	Mengidentifikasi bahwa tantangan terbesar arsitektur peramalan saat ini adalah adaptasi terhadap data iklim anomali tanpa sistem gabungan.	Memberikan peta evolusi teknologi prediksi bencana yang sangat jelas bagi peneliti. Meskipun begitu, studi ini hanya berupa pemetaan literatur dan tidak mengusulkan pengembangan arsitektur sistem komputasi yang baru.
10	<i>Edge Technologies for Disaster Management: A Survey of Social Media and Artificial Intelligence Integration (2023)</i>	Edge Computing & AI Integration	Aliran data (data stream) dari sensor IoT dan unggahan media sosial.	Pemrosesan pada Edge Node secara signifikan memotong latensi komunikasi darurat antar sistem.	Berhasil menyelesaikan hambatan komputasi skalabel untuk skenario tanggap darurat yang mendesak. Akan tetapi, fokusnya terlalu dominan di bidang infrastruktur jaringan dan kurang mengeksplorasi metode pemetaan genangnya.
11	<i>Low-Cost, Low-Energy, Wireless Hydrological Monitoring Platform: Design, Deployment, and Evaluation (2021)</i>	Wireless Sensor Network (WSN) / IoT	Data telemetri hidrologi (sensor ketinggian muka air).	Infrastruktur sensor nirkabel berbiaya rendah dan hemat energi sangat layak diandalkan untuk pengumpulan data lapangan yang kontinu.	Desain arsitektur pengumpulan data terbukti tervalidasi langsung di lapangan. Namun, skala datanya masih terbatas pada sisi edge lokal dan belum diproses di dalam lingkungan analisis Big Data secara utuh.
12	<i>A systematic literature review on the use of big data analytics in humanitarian and disaster operations (2022)</i>	Systematic Literature Review	Jurnal manajemen bencana dan operasi kemanusiaan.	<i>Big Data Analytics (BDA) mengoptimalkan distribusi logistik dan strategi evakuasi saat bencana alam.</i>	Menyoroti dengan baik aspek Value dari Mahadata untuk otoritas manajemen krisis. Kendati demikian, pembahasannya lebih difokuskan pada operasi logistik pasca-bencana dibandingkan kerangka peringatan dini.
13	<i>A Systematic Review of Disaster Management</i>	Systematic Review (Sistem Manajemen)	Literatur sistem peringatan dini dan	Sebagian besar sistem tanggap darurat saat ini bersifat	Berhasil mengkonfirmasi celah penelitian (research gap) utama tentang urgensi integrasi data multi-sumber

No	Judul Paper (Tahun)	Metode / Teknologi	Dataset	Hasil Utama	Kelebihan & Kekurangan
	<i>Systems: Approaches, Challenges, and Future Directions (2023)</i>	Bencana)	manajemen krisis global.	single-source (terfragmentasi) dan gagal diuji skalabilitas nya.	secara definitif. Kekurangannya, tidak ada eksperimen kuantitatif yang dilakukan untuk menguji efektivitas sistem pembandingan.
14	<i>A Component-Based Approach to Early Warning Systems: A Theoretical Model (2025)</i>	Component -Based Theoretical Modeling	Model konseptual Early Warning System (EWS).	EWS yang optimal tidak hanya memerlukan sensor pendeteksi, melainkan subsistem komunikasi risiko yang tersambung ke komunitas.	Memberikan landasan teori yang sangat kokoh untuk merancang komponen alur data (pipeline). Namun, konsep ini masih bersifat teoritis tanpa adanya demonstrasi implementasi sistem terdistribusi secara nyata di lapangan.

2.3 Research Gap dan Posisi Penelitian

Berdasarkan sintesis terhadap empat belas studi pada Tabel 3.1, ditemukan sejumlah pola umum serta celah penelitian (research gap) yang muncul secara konsisten. Pertama, sebagian besar penelitian sebelumnya masih menggunakan pendekatan satu dimensi atau single-source. Banyak studi menunjukkan keunggulan dalam pengolahan data spasial dan prediksi berbasis kecerdasan buatan [4], [14], namun cenderung mengabaikan aspek manusia. Sebaliknya, penelitian yang telah memasukkan variabel ketahanan sosial [2], [9] umumnya masih bersifat analisis statis dan belum mampu mengintegrasikan aliran data heterogen secara dinamis. Keterbatasan ini menyebabkan hasil pemetaan kerentanan belum mampu merepresentasikan kompleksitas kejadian bencana secara menyeluruh, di mana ancaman fisik dan kerentanan populasi saling berinteraksi.

Kedua, aspek skalabilitas sistem dalam memproses data spatio-temporal berskala Mahadata masih jarang diuji secara menyeluruh. Seperti yang diungkapkan dalam studi manajemen krisis global [12], sebagian besar sistem yang ada masih terfragmentasi dan menghadapi kesulitan dalam melakukan fusi data berukuran besar. Literatur yang tersedia juga belum secara komprehensif menguji arsitektur komputasi terdistribusi yang mampu melakukan proses ingest dan pengolahan data spasial berskala besar secara bersamaan dengan data tabel kependudukan dalam jumlah sangat besar, dengan tingkat latensi yang memadai untuk kebutuhan tanggap darurat.

Ketiga, penelitian mengenai pemetaan kerentanan banjir yang secara spesifik menggabungkan karakteristik geografis tropis dengan dinamika sosiodemografi lokal di Indonesia, seperti distribusi kelompok rentan dan kepadatan penduduk di wilayah perkotaan, masih sangat terbatas. Studi teknis yang ada umumnya hanya dilakukan dalam skala uji coba kecil berbasis sensor tunggal [10] atau lebih banyak berfokus pada konteks bencana di luar kondisi iklim dan geografi Indonesia [3], [5].

Penelitian ini bertujuan untuk menjawab ketiga celah tersebut melalui beberapa pendekatan utama, yaitu:

1. merancang sistem pemetaan kerentanan berbasis fusi data multi-sumber yang mengintegrasikan secara dinamis data spasial lingkungan, seperti curah hujan dari BMKG dan model elevasi, dengan data sosiodemografi seperti kepadatan penduduk dan profil kelompok rentan dari BPS;
2. mengimplementasikan arsitektur komputasi terdistribusi dengan memanfaatkan Apache Kafka untuk proses ingestion berkecepatan tinggi (Velocity) serta Apache Spark untuk pemrosesan paralel (Volume dan Variety) guna memastikan skalabilitas sistem dalam menghadapi lonjakan data; dan
3. menghasilkan luaran sistem yang disesuaikan dengan konteks risiko kebencanaan di Provinsi Lampung, sehingga pendekatan yang diusulkan dapat mendukung pengambilan keputusan strategis sesuai dengan standar operasional BNPB dan BPBD.


BAB III

METODOLOGI

3.1 Arsitektur Sistem

Sistem yang diusulkan menggunakan arsitektur komputasi terdistribusi untuk menangani karakteristik Volume, Velocity, dan Variety dari data kebencanaan. Arsitektur terdiri dari lima lapisan utama yaitu:

1. Data Ingestion Layer, Apache Kafka digunakan untuk mengelola asupan data berkecepatan tinggi (*Velocity*) dari sensor cuaca BMKG, API data penginderaan jauh, dan catatan statistik kependudukan BPS. Pada implementasi ini, Kafka dijalankan dalam mode simulasi berbasis memori lokal yang merepresentasikan empat topic utama, yaitu bmkg-curahhujan, gee-spasial, bps-sosiodemografi, dan bnpb-historis.
2. Storage Layer, memanfaatkan lingkungan komputasi terdistribusi seperti HDFS atau platform *cloud* untuk menyimpan volume data citra satelit multitemporal dan data tabel kependudukan yang sangat besar.
3. Processing Layer, sistem menggunakan Apache Spark untuk memfasilitasi pemrosesan paralel yang mampu menangani aspek Volume dan Variety data secara efisien, sementara Google Earth Engine (GEE) diintegrasikan untuk melakukan analisis spasial terhadap dinamika luasan banjir dan perubahan tutupan lahan.
4. Application Layer, menerapkan pendekatan *weighted vulnerability scoring* berbasis PySpark MLlib untuk mengevaluasi interaksi kompleks antara parameter fisik lingkungan (topografi, tutupan lahan) dengan karakteristik sosiodemografi masyarakat (kepadatan penduduk dan proporsi kelompok rentan) serta data historis kejadian banjir dari BNPB. Setiap parameter dinormalisasi menggunakan MinMaxScaler dari PySpark MLlib sebelum dikalikan dengan bobot yang telah ditentukan.
5. Visualization Layer, melalui dua bentuk keluaran peta kerentanan digital, yaitu peta statis berbasis Matplotlib dalam format PNG dan peta interaktif berbasis Folium dalam format HTML, yang keduanya dirancang untuk memberikan informasi komprehensif bagi instansi seperti BNPB dan BPBD Lampung dalam pengambilan keputusan mitigasi yang tepat sasaran.



Gambar 3.1 Arsitektur Lambda

3.2 Sumber Data dan Pengumpulan Data

Penelitian ini memanfaatkan data dari berbagai sumber untuk memperoleh gambaran kerentanan banjir yang lebih menyeluruh. Karakteristik Big Data dari data yang digunakan dapat dianalisis melalui tiga dimensi utama, yaitu volume, velocity, dan variety.

Dari sisi volume, data spasial seperti citra satelit topografi SRTM resolusi 30 meter serta data tutupan lahan MODIS yang diperoleh melalui Google Earth Engine menjadi komponen dengan ukuran terbesar dalam sistem. Satu set citra untuk wilayah Provinsi Lampung dapat mencapai ratusan gigabyte hingga terabyte. Selain itu, data tabel sosiodemografi dari Badan Pusat Statistik (BPS) mencakup seluruh kecamatan di Lampung, sementara data historis kejadian banjir dari Badan Nasional Penanggulangan Bencana (BNPB) memberikan tambahan informasi dari sisi waktu.

Dari sisi velocity, data curah hujan harian per kecamatan yang diperoleh dari Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) merupakan data dengan frekuensi pembaruan paling tinggi. Data ini diperbarui setiap hari dan dikumpulkan secara otomatis melalui integrasi API, dengan dukungan Apache Kafka sebagai pipeline ingestion untuk memastikan proses pengambilan data berjalan cepat dan stabil.

Dari sisi variety, sistem ini menggabungkan berbagai jenis data dengan format yang berbeda. Data cuaca berbentuk deret waktu tersedia dalam format JSON atau CSV, data geospasial disajikan dalam format raster seperti GeoTIFF, data kependudukan berbentuk tabel dalam format CSV atau Excel, serta data historis kejadian banjir dari BNPB. Perbedaan format ini menjadi tantangan utama dalam proses integrasi, yang kemudian diatasi melalui tahapan transformasi dan preprocessing agar seluruh data dapat digunakan secara terpadu. Tabel 3.1 berikut merangkum seluruh sumber data yang digunakan beserta format, volume, dan strategi pengumpulannya.

Tabel 3.1. Sumber dan Pengumpulan Data Penerapan Big Data di Bidang Kebencanaan

Sumber Data	Format	Volume	Strategi Pengumpulan
Data Curah Hujan per Kecamatan di Lampung dari BMKG	Data dikelola dalam format deret waktu (<i>time-series</i>) seperti JSON atau CSV melalui akses API	Volume relatif kecil karena dari website BMKG hanya mencatat curah hujan satu kali sehari	Pengumpulan data dilakukan secara otomatis melalui integrasi API resmi BMKG menggunakan platform Apache Kafka.
Data Topografi/Elevasi per Kecamatan di Lampung dari Google Earth Engine (GEE) SRTM 30m	Data tersedia dalam format <i>raster</i> (GeoTIFF). Data dikonversi ke format CSV untuk memudahkan pengolahan data.	Volume data ini merupakan komponen terbesar dalam sistem karena satu set citra satelit untuk wilayah provinsi dapat mencapai ukuran ratusan Gigabyte hingga Terabyte.	Pengumpulan data memanfaatkan platform berbasis <i>cloud</i> Google Earth Engine (GEE) melalui skrip otomatis untuk melakukan <i>crawling</i> dan <i>filtering</i> citra berdasarkan rentang waktu tertentu.
Data Tutupan Lahan (area hutan, sawah, pemukiman) per Kecamatan di Lampung dari Google Earth Engine (GEE) MODIS	Data tersedia dalam format <i>raster</i> (GeoTIFF).	Volume data ini merupakan komponen terbesar dalam sistem karena satu set citra satelit untuk wilayah provinsi dapat mencapai ukuran ratusan Gigabyte hingga Terabyte.	Pengumpulan data memanfaatkan platform berbasis <i>cloud</i> Google Earth Engine (GEE) melalui skrip otomatis untuk melakukan <i>crawling</i> dan <i>filtering</i> citra berdasarkan rentang waktu tertentu.
Data Kepadatan Penduduk per Kecamatan di Lampung dari BPS Lampung	Data dikelola dalam format CSV atau Excel.	Volumenya cukup besar karena mencakup data agregat hingga tingkat kecamatan di seluruh kabupaten/kota di Provinsi Lampung.	Pengumpulan dilakukan melalui metode <i>batch processing</i> dengan mengunduh dataset resmi dari portal Satu Data BPS Lampung.
Data Kelompok Rentan Penduduk per Kecamatan di Lampung dari BPS Lampung	Data dikelola dalam format CSV atau Excel.	Volumenya cukup besar karena mencakup data agregat hingga tingkat kecamatan di seluruh kabupaten/kota di Provinsi Lampung.	Pengumpulan dilakukan melalui metode <i>batch processing</i> dengan mengunduh dataset resmi dari portal Satu Data BPS Lampung.
Data Historis Kejadian Banjir di	Data dikelola dalam format CSV atau	Volume data per kejadian relatif	Pengumpulan data dilakukan melalui

Sumber Data	Format	Volume	Strategi Pengumpulan
Lampung dari BNPB	Excel.	kecil.	penarikan data historis (<i>historical data retrieval</i>) dari basis data resmi BNPB.

3.3 Pipeline data dan Preprocessing

Alur pemrosesan data dirancang untuk menangani asupan data secara terdistribusi dari berbagai sumber yang heterogen, mulai dari fase *ingestion* hingga data siap dianalisis. Pipeline ini memanfaatkan kerangka kerja Apache Spark untuk pemrosesan paralel dan Apache Kafka untuk manajemen aliran data berkelanjutan.

- Data Ingestion (Pengumpulan Data)

Aliran data deret waktu dengan kecepatan tinggi (*velocity*), seperti curah hujan harian dari API BMKG, ditangani menggunakan Apache Kafka. Sementara itu, data spasial statis bervolume masif (topografi dan tutupan lahan) diunduh secara berkala (*batch*) menggunakan skrip otomasi dari Google Earth Engine (GEE), dan data sosiodemografi dari portal BPS diekstraksi ke dalam sistem.

- Data Storage (Penyimpanan Data)

Seluruh data mentah (*raw data*) yang berhasil ditarik akan disimpan dalam *Hadoop Distributed File System* (HDFS) untuk memastikan skalabilitas dan keandalan penyimpanan bervolume besar (*Volume*).

- Data Cleaning (Pembersihan Data)

Proses ini dilakukan menggunakan Apache Spark (PySpark). Untuk data spasial, sistem akan mengidentifikasi dan menangani piksel yang rusak (*noise*) akibat tutupan awan pada citra satelit. Untuk data tabel (BMKG dan BPS), dilakukan imputasi nilai yang hilang (*missing values*) menggunakan metode interpolasi linear atau *mean substitution*, serta penyesuaian format tipe data dasar.

- Data Transformation (Transformasi Data)

Karena tingginya variasi format (*Variety*), data spasial berskala raster (GeoTIFF) dari GEE akan di-*resample* dan di-proyeksikan ulang ke sistem koordinat seragam (misalnya WGS 84). Data sosiodemografi akan dinormalisasi menggunakan metode *Min-Max Scaling* ke dalam rentang 0-1 agar bobot indikator kerentanan setara.

- Data Integration (Integrasi Data)

Proses fusi data dilakukan dengan teknik *Spatial Overlay*. Data tabel sosiodemografi dikaitkan dengan data spasial fisik berdasarkan batas administratif

kecamatan (*polygon*), sehingga menghasilkan satu *dataset* terintegrasi yang menyimpan parameter fisik dan sosial di setiap titik koordinat wilayah Lampung.

3.4 Metode Analisis/Model

Penelitian ini menggunakan pendekatan *weighted vulnerability scoring* berbasis PySpark MLlib yang mengintegrasikan lima parameter kerentanan secara multidimensi. Pendekatan ini dipilih karena mampu menggabungkan data fisik lingkungan dengan karakteristik sosiodemografi secara kuantitatif dan transparan, sehingga setiap komponen kerentanan dapat ditelusuri kontribusinya terhadap skor akhir.

Parameter yang dianalisis dalam model ini mencakup lima komponen utama beserta bobotnya masing-masing, yaitu:

1. Elevasi (bobot 0.35): parameter fisik utama yang mencerminkan potensi genangan. Skor elevasi dihitung secara inversi dari hasil normalisasi, yaitu $\text{skor_elevasi} = 1 - \text{elevasi_mean_norm}$, sehingga wilayah dengan elevasi rendah mendapatkan skor kerentanan yang lebih tinggi.
2. Tutupan Lahan (bobot 0.30): skor risiko tutupan lahan ditetapkan berdasarkan kode MODIS menggunakan peta risiko (TUTUPAN_RISK) dengan rentang 0.10–1.00, di mana kelas Permanent Wetlands (kode 11) memiliki skor tertinggi (1.00) dan kelas Evergreen Broadleaf Forest (kode 2) memiliki skor terendah (0.10).
3. Kepadatan Penduduk (bobot 0.20): data kepadatan penduduk per kabupaten dari BPS dinormalisasi menggunakan Min-Max Scaling ke rentang 0–1. Wilayah dengan kepadatan penduduk lebih tinggi mendapatkan skor kerentanan yang lebih besar karena potensi dampak banjir terhadap populasi lebih luas.
4. Proporsi Penduduk Rentan (bobot 0.10): dihitung sebagai proporsi kelompok usia anak (0–14 tahun) dan lansia (≥ 60 tahun) terhadap total populasi per kabupaten, kemudian dinormalisasi ke rentang 0–1. Kelompok ini diprioritaskan karena memiliki kapasitas adaptasi yang lebih rendah terhadap bencana banjir.
5. Frekuensi Historis Banjir (bobot 0.05): jumlah kejadian banjir tercatat per kabupaten dari data BNPB, dinormalisasi ke rentang 0–1. Parameter ini berfungsi sebagai validator empiris yang memperkuat skor kerentanan pada wilayah yang secara historis sering terdampak banjir.

Formula skor kerentanan total yang digunakan adalah sebagai berikut:

$$\begin{aligned} \text{skor_kerentanan} = & (\text{skor_elevasi} \times 0.35) + (\text{skor_tutupan} \times 0.30) + (\text{kepadatan_norm} \times 0.20) \\ & + (\text{proporsi_rentan_norm} \times 0.10) + (\text{frekuensi_banjir_norm} \times 0.05) \end{aligned}$$

Hasil skor kerentanan kemudian diklasifikasikan ke dalam lima kelas berdasarkan ambang batas berikut:

Tabel 3.2 Hasil Skor Kerentanan

Kelas Kerentanan	Rentang Skor
Sangat Tinggi	≥ 0.70
Tinggi	0.55 – 0.69
Sedang	0.40 – 0.54
Rendah	0.25 – 0.39
Sangat Rendah	< 0.25

Untuk mengukur tingkat keandalan dan performa dari sistem pemetaan kerentanan berbasis Mahadata ini, evaluasi dilakukan dengan menghitung Koefisien Korelasi Pearson antara skor kerentanan yang dihasilkan model dengan frekuensi kejadian banjir aktual dari data historis BNPB menggunakan fungsi `stat.corr()` pada PySpark. Nilai korelasi positif yang signifikan (>0.3) mengindikasikan bahwa skor model konsisten dengan pola kejadian banjir historis di wilayah Lampung.

BAB IV

DESAIN EKSPERIMEN

4.1 Skenario Eksperimen

Eksperimen pada penelitian ini dirancang untuk menguji performa model pemetaan kerentanan banjir secara spasial dan sosiodemografi . Skenario utama yang direncanakan meliputi :

1. Menguji akurasi model ketika hanya menggunakan parameter fisik tunggal seperti elevasi atau curah hujan saja, dibandingkan dengan model komprehensif yang mengintegrasikan data spasial dan sosiodemografi secara simultan.
2. Menguji performa pemrosesan *pipeline* data menggunakan Apache Spark dan Kafka dengan variasi ukuran dataset dari tingkat sampel kecil hingga data masif yaitu seluruh wilayah Provinsi Lampung untuk membuktikan ketahanan sistem terhadap lonjakan data.
3. Melakukan pengujian sensitivitas model dengan mengubah parameter bobot indikator risiko yaitu Elevasi, Tutupan Lahan, Kepadatan, Penduduk Rentan, dan Historis guna melihat dampaknya terhadap pergeseran klasifikasi zona kerentanan.

4.2 Baseline/Pembanding

Dalam eksperimen ini, metode *baseline* yang digunakan sebagai pembanding adalah model yang hanya mengandalkan parameter fisik lingkungan seperti topografi dan curah hujan saja karena mayoritas sistem peringatan dini dan manajemen bencana saat ini masih bergantung pada pendekatan fisik lingkungan saja dan mengabaikan aspek manusia. Dengan membandingkan model gabungan spasial dan sosiodemografi terhadap *baseline*, diharapkan dapat membuktikan secara kuantitatif bahwa penambahan variabel sosiodemografi meningkatkan presisi dan relevansi sosial dari peta risiko yang dihasilkan.

4.3 Environment Eksperimen

Tabel 4.1 Komponen yang dibutuhkan saat Eksperimen

Komponen	Spesifikasi
Hardware/Cloud	Google Colab
Sistem Operasi	Linux
Framework Big Data	Apache Spark, Apache Kafka, Apache Airflow
Bahasa Pemrograman	Python
Library Tools	Pyspark, geopandas, folium, mapclassify, scipy, pandas, numpy, dan matplotlib

4.4 Metriks Evaluasi

Evaluasi dilakukan untuk mengukur aspek akurasi spasial model serta performa komputasi sistem. Metriks yang digunakan untuk menguji akurasi spasial adalah Koefisien Korelasi Pearson (Pearson Correlation). Metriks ini digunakan untuk memvalidasi kedekatan antara skor kerentanan yang dihasilkan model komputasional dengan frekuensi kejadian banjir aktual dari data historis BNPB.

BAB V

HASIL YANG DIHARAPKAN


5.1 Hipotesis Hasil

Berdasarkan kajian teoretis dan komparasi terhadap model-model terdahulu, eksperimen integrasi data multidimensi ini diharapkan memberikan peningkatan performa yang signifikan baik dari sisi akurasi pemetaan maupun efisiensi komputasi.

Model fusi spasial-sosiodemografi diharapkan menghasilkan tingkat kesesuaian klasifikasi risiko 15% - 20% lebih tinggi dibandingkan dengan model *baseline*. Hal ini karena model *baseline* fisik seringkali memberikan penilaian kerentanan yang seragam pada elevasi yang sama. Padahal, dampak nyata banjir juga dapat ditentukan oleh jumlah populasi manusia di area tersebut. Dengan mengintegrasikan parameter kepadatan penduduk dan proporsi kelompok umur rentan ke dalam formula indeks, model ini mampu membedakan tingkat kerentanan wilayah. Sebagai contoh, Kota Metro dan Bandar Lampung yang memiliki topografi sedang namun berpenduduk padat akan terklasifikasi ke dalam zona dengan kerentanan yang tinggi.

5.2 Perancangan Visualisasi Hasil

Hasil dari eksperimen *pipeline* ini akan direpresentasikan dengan *Choropleth Map* dimana pembaca dapat melihat tingkat kerentanan tiap kabupaten yang ada di Lampung. Tingkat kerentanan akan diwakili oleh warna dimana hijau berarti tingkat kerentanan rendah, kuning berarti tingkat kerentanan sedang, oranye berarti tingkat kerentanan tinggi, dan merah berarti tingkat kerentanan sangat tinggi. Pada setiap kabupaten pun akan ada angka yang menunjukkan skor kerentanan akhir yang bernilai dari 0 - 1.0.



Gambar 5.1 Contoh Choropleth Map

5.3 Kontribusi yang Diharapkan

Penelitian pemetaan kerentanan banjir ini diharapkan memberikan kontribusi di beberapa aspek seperti :

1. Mengubah sistem pemetaan risiko banjir konvensional yang hanya berfokus pada topografi fisik menjadi model kerentanan dinamis yang juga berpusat pada manusia. Penelitian ini dapat menggunakan variabel demografi secara kuantitatif dalam kerangka komputasi terdistribusi.
2. Menyediakan rancangan *pipeline* big data yang dapat digunakan yang mengintegrasikan Apache Kafka dan Apache Spark yang dikontrol secara otomatis oleh Apache Airflow DAG. Pipeline ini dapat direplikasi untuk provinsi lain di Indonesia dengan sangat mudah.
3. Menghasilkan peta kerentanan yang dapat membantu BNPB dan BPBD Lampung untuk menentukan lokasi prioritas pembangunan infrastruktur pencegahan banjir dan merencanakan distribusi bantuan ke wilayah dengan indeks kelompok rentan yang tinggi.

BAB VI

KESIMPULAN

6.1 Kesimpulan

Penelitian ini berhasil merancang dan mensimulasikan sebuah pipeline big data terintegrasi untuk memetakan tingkat kerentanan banjir di Provinsi Lampung secara multidimensi. Berbeda dengan model konseptual konvensional yang hanya mengandalkan parameter fisik permukaan bumi, pendekatan yang diusulkan mengintegrasikan data spasial fisik dengan karakteristik sosiodemografi regional seperti kepadatan penduduk dan proporsi kelompok umur rentan melalui teknik fusi data terdistribusi. Pipeline ini disusun secara sistematis menggunakan Apache Airflow DAG, dengan Apache Kafka bertindak sebagai pengelola asupan data dinamis, dan Apache Spark sebagai mesin pemroses utama untuk melakukan transformasi, pembersihan, integrasi spasial, hingga kalkulasi indeks skor kerentanan fusi menggunakan pustaka PySpark MLlib.

Kontribusi utama yang diharapkan dari penelitian ini adalah penyediaan model kerentanan banjir yang berpusat pada manusia untuk meningkatkan presisi mitigasi bencana taktis. Dengan pembobotan terkalibrasi yaitu 65% parameter fisik, 30% parameter sosiodemografi, dan 5% data kejadian historis, model ini mampu mengidentifikasi wilayah-wilayah yang memiliki kerentanan tinggi akibat tingginya konsentrasi penduduk usia non-produktif, meskipun berada pada topografi elevasi sedang seperti Kota Metro dan Kota Bandar Lampung. Hasil fusi data yang divisualisasikan dalam bentuk *Choropleth Map* yang diharapkan dapat berfungsi sebagai sistem pendukung keputusan yang valid bagi BNPB dan BPBD Lampung dalam memprioritaskan evakuasi, pendirian posko penyelamatan, dan distribusi bantuan bagi warga yang paling membutuhkan secara cepat dan akurat.

6.2 Keterbatasan Penelitian

Meskipun model rancangan sistem dan alur fusi data telah berhasil diimplementasikan secara fungsional, beberapa keterbatasan dalam eksperimen ini adalah sebagai berikut :

1. Data curah hujan harian dari BMKG belum terhubung ke API sensor fisik yang sesungguhnya secara real-time. Komponen Apache Kafka masih dijalankan secara simulasi memori lokal, sehingga aspek latensi jaringan dan konkurensi data stream belum diukur secara riil dalam kluster terdistribusi.
2. Penetapan titik spasial ke tingkat kabupaten/kota masih menggunakan pendekatan nearest centroid menggunakan koordinat centroid ibu kota kabupaten dan algoritma

KDTree. Pendekatan ini merupakan penyederhanaan dari Voronoi approximation yang memiliki tingkat bias spasial tinggi di area perbatasan wilayah administratif.

3. Meskipun infrastruktur dirancang untuk skala big data, pemrosesan fusi data akhir dikurangi menjadi dataset agregat berukuran kecil yang hanya berisi 14 baris data representasi kabupaten. Akibatnya, efisiensi komputasi terdistribusi Apache Spark dan ketahanan memori terhadap bottleneck Out-of-Memory (OOM) belum teruji secara empiris menggunakan data spasial berskala Gigabyte/Terabyte yang sesungguhnya.
4. Penentuan bobot kerentanan banjir masih didasarkan pada asumsi heuristik peneliti berdasarkan literatur, bukan hasil pembelajaran otomatis oleh model.

6.3 Rencana Pengembangan

Berdasarkan keterbatasan yang telah diidentifikasi, rencana pengembangan ke depan meliputi beberapa aspek berikut:

1. Integrasi API Real-Time dan Deployment Kluster Terdistribusi

Mengganti simulasi Kafka berbasis memori lokal dengan koneksi langsung ke API BMKG secara real-time dan men-deploy pipeline pada kluster Apache Spark sesungguhnya, baik on-premise maupun berbasis cloud, agar latensi dan skalabilitas sistem dapat diukur secara empiris.

2. Peningkatan Resolusi Spasial ke Tingkat Kecamatan

Menggantikan pendekatan nearest centroid KDTree dengan Spatial Join berbasis polygon menggunakan data vektor batas kecamatan dari BPS, sehingga skor kerentanan dapat dihitung pada resolusi spasial yang lebih halus dan minim bias di area perbatasan.

3. Pengujian Skalabilitas dengan Data Skala Penuh

Melakukan pengujian pipeline menggunakan data spasial GeoTIFF berukuran Gigabyte hingga Terabyte yang sesungguhnya untuk mengukur throughput PySpark, konsumsi memori, dan potensi bottleneck OOM secara empiris.

4. Kalibrasi Bobot Otomatis Berbasis Machine Learning

Mengganti penetapan bobot heuristik dengan metode data-driven seperti AHP berbasis survei pakar, Random Forest Feature Importance, atau Genetic Algorithm agar skor kerentanan yang dihasilkan lebih objektif dan dapat direproduksi.

5. Replikasi Pipeline ke Provinsi Lain

Memanfaatkan sifat modular Airflow DAG untuk memperluas cakupan analisis ke provinsi lain di Indonesia dengan substitusi parameter konfigurasi wilayah, sehingga manfaat penelitian ini dapat dirasakan lebih luas oleh BNPB dan BPBD di tingkat nasional.

REFERENSI

- [1] A. Sigit, M. Koyama, and M. Harada, "Flood Risk Assessment Focusing on Exposed Social Characteristics in Central Java, Indonesia," *Sustainability*, vol. 15, no. 24, p. 16856, Dec. 2023, doi: 10.3390/su152416856.
- [2] A. Sigit and M. Harada, "Land Cover and Socioeconomic Analysis for Recommended Flood Risk Reduction Strategies in Java Island, Indonesia," *Sustainability*, vol. 16, no. 15, p. 6475, Jul. 2024, doi: 10.3390/su16156475.
- [3] S. Sarker, I. Jahan, X. Wang, and A. Azad, "Geospatial Approach to Assess Flash Flood Vulnerability in a Coastal District of Bangladesh: Integrating the Multifaceted Dimension of Vulnerabilities," *ISPRS International Journal of Geo-Information*, vol. 14, no. 5, p. 194, May 2025, doi: 10.3390/ijgi14050194.
- [4] S. Aldiansyah, L. M. Irsan, and N. Hasanah, "Multi-Temporal Analysis of Flood Dynamics and Land Use Land Cover Change in the Konawe Watershed Using Multi-Sensor Remote Sensing Approach," *Journal of Landscape Ecology*, Feb. 2026, doi: 10.2478/jlecol-2026-0021.
- [5] J. Liu, J. Lee, and R. Zhou, "Review of big-data and AI application in typhoon-related disaster risk early warning in Typhoon Committee region," *Tropical Cyclone Research and Review*, vol. 12, no. 4, pp. 341–353, Dec. 2023, doi: 10.1016/j.tcr.2023.12.004.
- [6] S. Gao, T. Yang, Y. Xu, N. Mou, X. Wang, and H. Huang, "Enhancing Disaster Situation Awareness Through Multimodal Social Media Data: Evidence from Typhoon Haikui," *Applied Sciences*, vol. 15, no. 1, p. 465, Jan. 2025, doi: 10.3390/app15010465.
- [7] B. Kuhaneswaran, G. Sorwar, A. R. Alaei, and F. Tong, "Evolution of Data-Driven Flood Forecasting: Trends, Technologies, and Gaps—A Systematic Mapping Study," *Water*, vol. 17, no. 15, p. 2281, Jul. 2025, doi: 10.3390/w17152281.
- [8] M. Aboualola, K. Abualsaud, T. Khattab, N. Zorba, and H. S. Hassanein, "Edge Technologies for Disaster Management: A Survey of Social Media and Artificial Intelligence Integration," *IEEE Access*, vol. 11, pp. 73782–73802, 2023, doi: 10.1109/access.2023.3293035.
- [9] R. Srivastava, S. Pathak, Lakshmanan, D. Sharma, B. Bhushan, and Mahalakshmi, "Novel data-driven model for flood prediction using big data: Social resilience and risk management," *Multidisciplinary Science Journal*, vol. 7, p. 2025ss0315, Sep. 2025, doi: 10.31893/multiscience.2025ss0315.
- [10] Q. Abdelal and A. Al-Hmoud, "Low-Cost, Low-Energy, Wireless Hydrological Monitoring Platform: Design, Deployment, and Evaluation," *Journal of Sensors*, vol. 2021,

no. 1, Jan. 2021, doi: 10.1155/2021/8848955.

[11] A. Kondraganti, G. Narayanamurthy, and H. Sharifi, “A systematic literature review on the use of big data analytics in humanitarian and disaster operations,” *Annals of Operations Research*, vol. 335, no. 3, pp. 1015–1052, Nov. 2022, doi: 10.1007/s10479-022-04904-z.

[12] S. M. Khan *et al.*, “A Systematic Review of Disaster Management Systems: Approaches, Challenges, and Future Directions,” *Land*, vol. 12, no. 8, p. 1514, Jul. 2023, doi: 10.3390/land12081514.

[13] D. Chovanec, B. Kollár, B. Halúsková, J. Kubás, M. Pawęska, and J. Ristvej, “A Component-Based Approach to Early Warning Systems: A Theoretical Model,” *Applied Sciences*, vol. 15, no. 6, p. 3218, Mar. 2025, doi: 10.3390/app15063218.

[14] F. Qin, C. Huang, and Z. Lin, “Big data and artificial intelligence-driven natural disaster prediction and prevention: Technological advances and prospects,” *Geographical Research Bulletin*, vol. 3, pp. 381–398, Oct. 2024, doi: 10.50908/grb.3.0_381.

LAMPIRAN

[Repository Github](#)